

Airbnb 집값예측

목차

01 분석 배경

02 데이터 소개

03 데이터 전처리

04 모델링

05 모델 평가

06 결론

01 분석 배경


에어비앤비 가격예측

목적: 에어비앤비 예약 및 대여를 원활하게 하기 위해
집의 조건에 맞는 적절한 가격을 책정한다.

타겟 고객: 에어비앤비 호스트 및 방문자

대여사업을 시작하는 호스트에게 적절한 가격을 제안함으로써
안정적인 수익 보장

예약을 적절한 가격에 하고싶은 방문자에게 원하는 조건에
서 최적의 가격인 숙소 정보를 제공



02 데이터 소개

Airbnb price prediction 출처: <https://www.kaggle.com/datasets/stevezhenghp/airbnb-price-prediction>

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 74111 entries, 0 to 74110
Data columns (total 16 columns):
#   Column                Non-Null Count  Dtype
---  -
0   log_price              74111 non-null  float64
1   property_type          74111 non-null  object
2   room_type              74111 non-null  object
3   amenities              74111 non-null  object
4   accommodates           74111 non-null  int64
5   bathrooms              73911 non-null  float64
6   bed_type               74111 non-null  object
7   cancellation_policy    74111 non-null  object
8   cleaning_fee           74111 non-null  bool
9   city                   74111 non-null  object
10  latitude                74111 non-null  float64
11  longitude               74111 non-null  float64
12  number_of_reviews      74111 non-null  int64
13  review_scores_rating    57389 non-null  float64
14  bedrooms                74020 non-null  float64
15  beds                   73980 non-null  float64
dtypes: bool(1), float64(7), int64(2), object(6)
memory usage: 8.6+ MB
```

총 29개 변수
74111개의 데이터로 구성

지역: 미국 (뉴욕, 로스앤젤레스, 샌프란시스코, 워싱턴 DC, 시카고, 보스턴)

대여사업을 시작하는 호스트에게 적절한 가격을 제안함으로써 안정적인 수익 보장

예약을 적절한 가격에 하고싶은 방문자에게 원하는 조건에서 최적의 가격인 숙소 정보를 제공

03 데이터 전처리 변수 제거

#남은 변수 확인

df.info()

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 74111 entries, 0 to 74110
Data columns (total 16 columns):
 #   Column              non-null count
---  --
 0   log_price           74111
 1   property_type       74111
 2   room_type           74111
 3   amenities           74111
 4   accommodates        74111
 5   bathrooms           74111
 6   bed_type            74111
 7   cancellation_policy 74111
 8   cleaning_fee        74111
 9   city                74111
10   latitude            74111
11   longitude           74111
12   number_of_reviews   74111
13   review_scores_rating 74111
14   bedrooms            74111
15   beds                74111
dtypes: bool(1), float64(7), int64(8)
memory usage: 8.6+ MB
```


#결측값 확인

df.isnull().sum()

```
log_price           0
property_type       0
room_type           0
amenities           0
accommodates        0
bathrooms           200
bed_type            0
cancellation_policy 0
cleaning_fee        0
city                0
latitude            0
longitude           0
number_of_reviews   0
review_scores_rating 16722
bedrooms            91
beds                131
dtype: int64
```

#결측치 제거

```
df.dropna(axis=0, how='any', inplace=True)
df = df.reset_index(drop=True)
```



```
[ ] Q1=df['log_price'].quantile(0.25)
    Q3=df['log_price'].quantile(0.75)
    IQR=Q3-Q1
```

```
lb = Q1-1.5*IQR
ub=Q3+1.5*IQR
```

```
[ ] outliers_idx = []
```

```
outliers_idx.extend(df[(df['log_price'] < lb) | (df['log_price'] > ub)].index)
len(outliers_idx)
```

935

결측치 및 이상치, 무의미한 변수 제거 -> 16개 변수, 57129개의 데이터

03 데이터 전처리 원핫인코딩

#변수 합치기

```
df['property_type']=df['property_type'].replace({'Hostel':'Guesthouse','In-law':'Guest suite','Townhouse':'House',
```

```
<ipython-input-45-fdae7f1930ba>:2: SettingWithCopyWarning:  
A value is trying to be set on a copy of a slice from a DataFrame.  
Try using .loc[row_indexer,col_indexer] = value instead
```

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#return
df['property_type']=df['property_type'].replace({'Hostel':'Guesthouse','In-law':'Guest suite','Townhouse':'House

```
df['property_type'].value_counts()
```





```
Apartment      37294  
House          13773  
Condominium    1953  
Loft           976  
Guesthouse     537  
Bed & Breakfast 350  
Bungalow       305  
Vacation home  178  
Guest suite    162  
Name: property_type, dtype: int64
```

```
df['pool'] = df['amenities'].apply(lambda x: 1 if "Pool" in x else 0)  
df['breakfast'] = df['amenities'].apply(lambda x: 1 if "Breakfast" in x else 0)  
df['internet'] = df['amenities'].apply(lambda x: 1 if "Internet" or "Wireless Internet" or "Pocket wifi" in x else 0)  
df['kitchen'] = df['amenities'].apply(lambda x: 1 if "Kitchen" in x else 0)  
df['free parking on premises'] = df['amenities'].apply(lambda x: 1 if "Free parking on premises" in x else 0)  
df['air-conditioning or heating'] = df['amenities'].apply(lambda x: 1 if "Air conditioning" or "Heating" in x else 0)  
df['hot tub'] = df['amenities'].apply(lambda x: 1 if "Hot tub" in x else 0)  
df['washer'] = df['amenities'].apply(lambda x: 1 if "Washer" in x else 0)  
df['dryer'] = df['amenities'].apply(lambda x: 1 if "Dryer" in x else 0)  
df['self check-in'] = df['amenities'].apply(lambda x: 1 if "Self Check-In" in x else 0)  
df['tv'] = df['amenities'].apply(lambda x: 1 if "TV" or "Cable TV" in x else 0)
```

범주형 변수 범주 줄이기, 필수 편의시설 원핫인코딩 -> 27개의 변수, 55528개의 데이터

03 데이터 전처리

데이터 탐색 및 시각화



Stata를 이용한 T-test

-95% 신뢰수준에서, 모두 유의성 존재함으로 나옴.

-변수 어메니티를 보유하지 않는 숙소(0) - 보유하는 숙소(1)를 기준으로 측정 -> t값이 음수인 경우 어메니티 보유와 숙소 가격이 양의 관계를 가지고 있다고 해석할 수 있음.

-조식의 경우 오히려 없는 경우가 더 숙소 값이 높다고 나옴.

room type, cancellation policy, bedrooms, accommodates 등이 log_price와 관련성 높음

04 모델링

이용 모델 다층 퍼셉트론

✓ 훈련데이터 테스트데이터 분할하기

```
[ ] X = df.drop('log_price', axis=1)
    y = df['log_price']

    # 데이터를 7:3 비율로 분할
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)
```

✓ 모델 구축

```
model = Sequential()
model.add(Dense(64, activation = 'relu', input_dim = 26))
model.add(Dense(32, activation = 'relu'))
model.add(Dense(16, activation = 'relu'))
model.add(Dense(8, activation = 'relu'))
model.add(Dense(1, activation = 'linear'))

model.compile(optimizer = 'adam', loss = 'mean_squared_error')



# early stopping 적용
from keras.callbacks import EarlyStopping
early_stopping = EarlyStopping(monitor='loss', patience=3, restore_best_weights=True)
```

✓ 모델 학습

```
[ ] model.fit(X_train, y_train, epochs=50, batch_size=20, callbacks = [early_stopping])
```

✓ 모델 요약

```
from tensorflow.keras.utils import plot_model
plot_model(model, show_shapes=True, to_file='model.png')
```



범주형 변수 범주 줄이기, 필수 편의시설 원핫인코딩 -> 27개의 변수, 55528개의 데이터

05 모델 평가

R^2



MSE

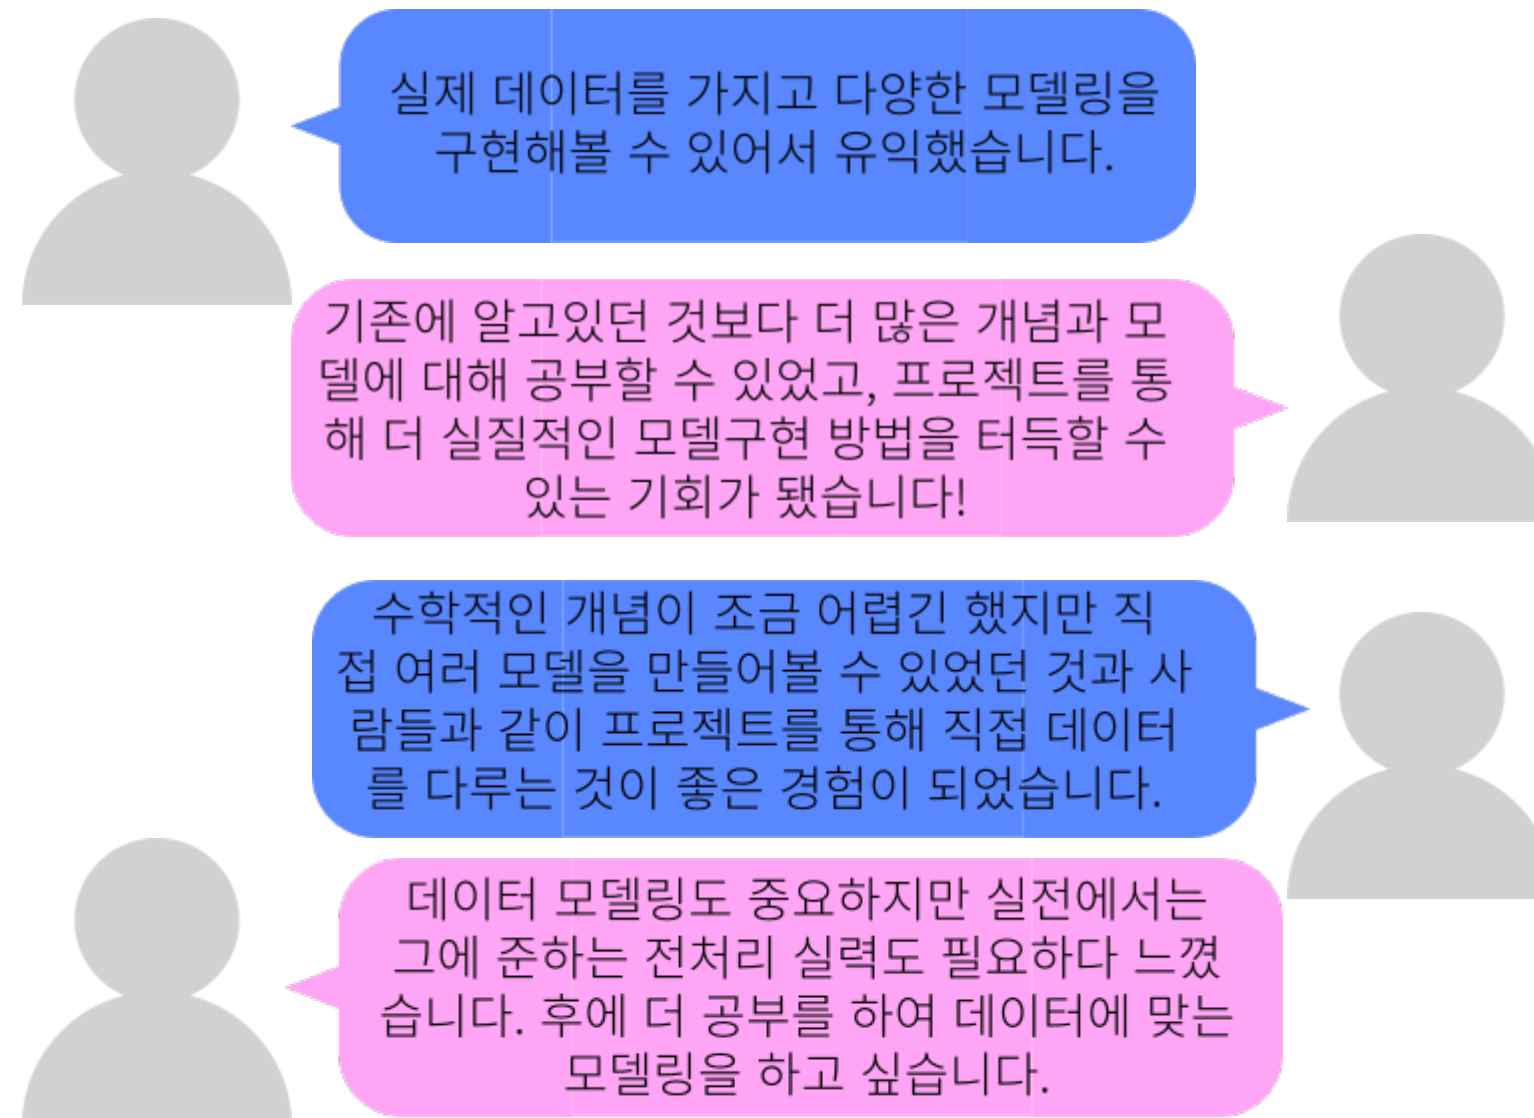


06 결론

활용방안 및 시사점

1. 집 특성, 수용인원, 편의시설 등에 따른 **에어비앤비 가격**을 예측할 수 있음
2. 에어비앤비 가격 책정 특성 상 변수와 가격 간의 **명확한 상관관계**를 찾기 어려움
3. 다층퍼셉트론 모델을 사용하여 **결과 해석이 어려움**
4. 더 명확한 데이터 **전처리를 통해 개선 가능할 것**으로 보임

느낀점



실제 데이터를 가지고 다양한 모델링을 구현해볼 수 있어서 유익했습니다.

기존에 알고있던 것보다 더 많은 개념과 모델에 대해 공부할 수 있었고, 프로젝트를 통해 더 실질적인 모델구현 방법을 터득할 수 있는 기회가 됐습니다!

수학적인 개념이 조금 어렵긴 했지만 직접 여러 모델을 만들어볼 수 있었던 것과 사람들과 같이 프로젝트를 통해 직접 데이터를 다루는 것이 좋은 경험이 되었습니다.

데이터 모델링도 중요하지만 실전에서는 그에 준하는 전처리 실력도 필요하다 느꼈습니다. 후에 더 공부를 하여 데이터에 맞는 모델링을 하고 싶습니다.