

Airbnb 집값예측

목차

01	분석 배경
02	데이터 소개
03	데이터 전처리
04	모델링
05	모델 평가
06	결론

01 분석 배경


에어비앤비 가격예측

목적: 에어비앤비 예약 및 대여를 원활하게 하기 위해
집의 조건에 맞는 적절한 가격을 책정한다.

타겟 고객: 에어비앤비 호스트 및 방문자

대여사업을 시작하는 호스트에게 적절한 가격을 제안함으로써
안정적인 수익 보장

예약을 적절한 가격에 하고싶은 방문자에게 원하는 조건에
서 최적의 가격인 숙소 정보를 제공



02 데이터 소개

Airbnb price prediction 출처: <https://www.kaggle.com/datasets/stevezhenghp/airbnb-price-prediction>

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 74111 entries, 0 to 74110
Data columns (total 16 columns):
#   Column                Non-Null Count  Dtype
---  ---
0   log_price              74111 non-null  float64
1   property_type          74111 non-null  object
2   room_type              74111 non-null  object
3   amenities              74111 non-null  object
4   accommodates           74111 non-null  int64
5   bathrooms              73911 non-null  float64
6   bed_type               74111 non-null  object
7   cancellation_policy    74111 non-null  object
8   cleaning_fee           74111 non-null  bool
9   city                   74111 non-null  object
10  latitude                74111 non-null  float64
11  longitude               74111 non-null  float64
12  number_of_reviews       74111 non-null  int64
13  review_scores_rating    57389 non-null  float64
14  bedrooms                74020 non-null  float64
15  beds                   73980 non-null  float64
dtypes: bool(1), float64(7), int64(2), object(6)
memory usage: 8.6+ MB
```

총 29개 변수
74111개의 데이터로 구성

지역: 미국 (뉴욕, 로스앤젤레스, 샌프란시스코, 워싱턴 DC, 시카고, 보스턴)

대여사업을 시작하는 호스트에게 적절한 가격을 제안함으로써 안정적인 수익 보장

예약을 적절한 가격에 하고싶은 방문자에게 원하는 조건에서 최적의 가격인 숙소 정보를 제공

03 데이터 전처리 변수 제거

#남은 변수 확인

df.info()

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 74111 entries, 0 to 74110
Data columns (total 16 columns):
 #   Column              non-null count
---  --
 0   log_price            74111
 1   property_type        74111
 2   room_type            74111
 3   amenities            74111
 4   accommodates         74111
 5   bathrooms            74111
 6   bed_type             74111
 7   cancellation_policy  74111
 8   cleaning_fee         74111
 9   city                 74111
10  latitude             74111
11  longitude            74111
12  number_of_reviews    74111
13  review_scores_rating  74111
14  bedrooms             74111
15  beds                74111
dtypes: bool(1), float64(7), int64(8)
memory usage: 8.6+ MB
```


#결측값 확인

df.isnull().sum()

```
log_price            0
property_type        0
room_type            0
amenities            0
accommodates         0
bathrooms            200
bed_type             0
cancellation_policy  0
cleaning_fee         0
city                 0
latitude             0
longitude            0
number_of_reviews    0
review_scores_rating 16722
bedrooms             91
beds                 131
dtype: int64
```

#결측치 제거

```
df.dropna(axis=0, how='any', inplace=True)
df = df.reset_index(drop=True)
```



```
[ ] Q1=df['log_price'].quantile(0.25)
    Q3=df['log_price'].quantile(0.75)
    IQR=Q3-Q1
```

```
lb = Q1-1.5*IQR
ub=Q3+1.5*IQR
```

```
[ ] outliers_idx = []
```

```
outliers_idx.extend(df[(df['log_price'] < lb) | (df['log_price'] > ub)].index)
len(outliers_idx)
```

935

결측치 및 이상치, 무의미한 변수 제거 -> 15개 변수, 57129개의 데이터

03 데이터 전처리 원핫인코딩

#변수 합치기

```
df['property_type']=df['property_type'].replace({'Hostel':'Guesthouse','In-law':'Guest suite','Townhouse':'House',
```

<ipython-input-45-fdae7f1930ba>:2: SettingWithCopyWarning:

A value is trying to be set on a copy of a slice from a DataFrame.

Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#return

```
df['property_type']=df['property_type'].replace({'Hostel':'Guesthouse','In-law':'Guest suite','Townhouse':'House
```

```
df['property_type'].value_counts()
```


Apartment	37294
House	13773
Condominium	1953
Loft	976
Guesthouse	537
Bed & Breakfast	350
Bungalow	305
Vacation home	178
Guest suite	162
Name: property_type, dtype: int64	

```
df['pool'] = df['amenities'].apply(lambda x: 1 if "Pool" in x else 0)
df['breakfast'] = df['amenities'].apply(lambda x: 1 if "Breakfast" in x else 0)
df['internet'] = df['amenities'].apply(lambda x: 1 if "Internet" or "Wireless Internet" or "Pocket wifi" in x else 0)
df['kitchen'] = df['amenities'].apply(lambda x: 1 if "Kitchen" in x else 0)
df['free parking on premises'] = df['amenities'].apply(lambda x: 1 if "Free parking on premises" in x else 0)
df['air-conditioning or heating'] = df['amenities'].apply(lambda x: 1 if "Air conditioning" or "Heating" in x else 0)
df['hot tub'] = df['amenities'].apply(lambda x: 1 if "Hot tub" in x else 0)
df['washer'] = df['amenities'].apply(lambda x: 1 if "Washer" in x else 0)
df['dryer'] = df['amenities'].apply(lambda x: 1 if "Dryer" in x else 0)
df['self check-in'] = df['amenities'].apply(lambda x: 1 if "Self Check-In" in x else 0)
df['tv'] = df['amenities'].apply(lambda x: 1 if "TV" or "Cable TV" in x else 0)
```

범주형 변수 범주 줄이기, 필수 편의시설 원핫인코딩 -> 26개의 변수, 55528개의 데이터

03 데이터 전처리

데이터 탐색 및 시각화




Stata를 이용한 T-test

-95% 신뢰수준에서, 모두 유의성 존재함으로 나옴.


-변수 어메니티를 보유하지 않는 숙소(0) - 보유하는 숙소(1)를 기준으로 측정 -> t값이 음수인 경우 어메니티 보유와 숙소 가격이 양의 관계를 가지고 있다고 해석할 수 있음.

-조식의 경우 오히려 없는 경우가 더 숙소 값이 높다고 나옴.


Violin Plot for room_type vs. log_price



Scatter Plot for bedrooms vs. log_price



Violin Plot for cancellation_policy vs. log_price



room type, cancellation policy, bedrooms, accommodates 등이 log_price와 관련성 높음

04 모델링

이용 모델 다층 퍼셉트론

✓ 훈련데이터 테스트데이터 분할하기

```
X = df[feature_columns]
y = df['log_price']

# 데이터를 7:3 비율로 분할
X_train, X_temp, y_train, y_temp = train_test_split(X, y, test_size = 0.3, random_state = 42)

# 30%의 데이터를 다시 검증, 테스트 데이터로 분할
X_val, X_test, y_val, y_test = train_test_split(X_temp, y_temp, test_size = 0.5, random_state = 42)
```

✓ 모델 구축

```
model = Sequential()
model.add(Dense(64, activation = 'relu', input_dim = 26))
model.add(Dense(32, activation = 'relu'))
model.add(Dense(16, activation = 'relu'))
model.add(Dense(8, activation = 'relu'))
model.add(Dense(1, activation = 'linear'))

model.compile(optimizer = 'adam', loss = 'mean_squared_error')



# early stopping 적용
from keras.callbacks import EarlyStopping
early_stopping = EarlyStopping(
    monitor='val_loss',
    patience=3,
    restore_best_weights=True
)
```

✓ 모델 학습

```
[ ] model.fit(X_train, y_train, epochs=50, batch_size=20, callbacks = [early_stopping])
```

✓ 모델 요약

```
from tensorflow.keras.utils import plot_model
plot_model(model, show_shapes=True, to_file='model.png')
```



범주형 변수 범주 줄이기, 필수 편의시설 원핫인코딩 -> 26개의 변수, 55528개의 데이터

05 모델 평가

R^2



MSE



06 결론

활용방안 및 시사점

1. 집 특성, 수용인원, 편의시설 등에 따른 **에어비앤비 가격**을 예측할 수 있음
2. 에어비앤비 가격 책정 특성 상 변수와 가격 간의 **명확한 상관관계**를 찾기 어려움
3. 다층퍼셉트론 모델을 사용하여 **결과 해석이 어려움**
4. 더 명확한 데이터 **전처리**를 통해 개선 가능할 것으로 보임

느낀점

